

מעבדה בסטיסטיקה 52568 התשע"ח בוחן מסכם – דף הנחיות.

הנחיות: הבוחן כולל 2 שאלות המורכבות ממספר סעיפים. עליכם לענות בטופס הבחינה ובאופן עצמאי על כל השאלות. יש להסביר בקצרה כל תשובה במקום הנתון לה בלבד ובכתב ברור.

חומר עזר: מחשבון.


משך הבחינה: שעה

שאלה 1

עדי רוצה לאמוד קו רגרסיה המקשר בין מספר הפרגמנטים בתא וכמות הGC. היא החליטה לאמוד רגרסיה המורכבת ממקטעים ישרים, וכתבה את הנוסחה הבאה:

```
lm(formula = FRAG ~ I(1 * ( GC <0.4 ) ) + I(GC * ( GC <0.4 ) ) +  
I(1 * ( GC >=0.4 ) ) + I(GC * ( GC >=0.4)), subset = train_samp)
```

הרגרסיה שאמדה מסומנת בקו מלא בגרף.



א. [15 נק']

נסמן ב- X את מטריצת המודל הלינארי (ב-4 עמודות וח שורות). כתבו את השורות של X המתאימות לנקודה עם $GC=0.3$ ולנקודה עם $GC=0.5$.

$$X_{0.3} = (1, 0.3, 0, 0)$$

$$X_{0.5} = (0, 0, 1, 0.5)$$

ב. [20 נק']

ראזי הציע לעשות רגרסיית מקלות שבורים במקום הרגרסיה של עדי. הרגרסיה מתוארת בקו מנוקד. סמנו את התשובה הנכונה והסבירו בקצרה.

ההטיה בריבוע הממוצעת של המודל החדש (ראזי):

1. גדולה משל המודל של עדי.

2. קטנה מהמודל של עדי.

3. לא ניתן לדעת.

בפונקציה של ראזי נוסף אילוץ לעומת הפונקציה של עדי, כלומר יש רק 3 פרמטרים חופשיים לעומת

4 אצל עדי. ההטיה יורדת (או לפחות לא עולה) ככל שמרחב הפונקציות גדל. במקרה הזה, קל

לראות שההטיה תרד ממש מפני שגם האומד של עדי וגם האומד של ראזי אינם מתאימים לנתונים,

ולכן הגמישות הנוספת של עדי בוודאי תוריד את ההטיה.

ג. [10 נק']

הסבירו מדוע נקודת אי רציפות, כמו זו שיש במודל של עדי, היא תכונה לא רצויה עבור פונקציית GC . (רמז – מה יקרה כשנסה לאמוד עותקים?).

כאשר ננסה לאמוד עותקים בעזרת פונקציית GC לא רציפה, שינוי קטן ב- GC יצור שינוי גדול במספר העותקים הנאמד. כאשר אנחנו רואים שינויים חדים במספר העותקים הנאמד, אנחנו בד"כ חושבים שמדובר בשינוי במספר העותקים האמיתי; פה פונקציה לא רציפה ברגרסיה יכולה להטעות אותנו.

שאלה 2

דן רוצה לבדוק את התפלגות הפרגמנטים ב-10,000 תאים. הוא משתמש בפונקציית היסטוגרמה ומקבל את הגרף והפלט הבאים:

```

> h
$breaks
[1] 50 100 150 200 250 300 350

$counts
[1] 24 1353 3699 3601 1248 75

$density
[1] 0.000048 0.002706 0.007398 0.007202 0.002496 0.000150


$mids
[1] 75 125 175 225 275 325

$xname
[1] "dat"

$equidist
[1] TRUE

attr(,"class")
[1] "histogram"

```



א. [15 נקודות] הציעו שלושה שיפורים שיהפכו את הגרף ליותר אינפרמטיבי.
יש שיפורים רבים שניתן לעשות. אני מסדר מחשוב לפחות חשוב:

1. לחלק להרבה יותר תאים, כדי שנוכל לראות את צורת ההתפלגות.
2. לשם כותרת אינפורמטיבית שנדע מהו המשתנה ושם על ציר הא.
3. לסמן תוחלת בקו אנכי.
4. מספרים על העמודות שנוכל לכמת.
5. לכתוב מהו הסה"כ כדי שנדע איזה חלק מההתפלגות כל עמודה.
6. צבעים, גודל פונט.

ב. **[10 נק']** השתמשו בהסטוגרמה כדי לאמוד בקירוב את $E[Y]$ ואת $\text{Var}[Y]$.

דרך המלך במקרים האלו היא להחליף את כל ערך של Y בתא הרלוונטי שהוא נופל בהסטוגרמה.

כך, כל Y שהיה בין 100 ל-150 נניח שיצא בדיוק 125. אנחנו קצת נאבד שונות אך לא נורא לעניינינו.

לגבי התוחלת נקבל אומד טוב יחסית. לפי החישוב הזה:

$$E[Y] \approx \frac{24 \cdot 75 + 1353 \cdot 125 + 3699 \cdot 175 + 3601 \cdot 225 + 1248 \cdot 275 + 75 \cdot 325}{10,000} = 199.605$$

מתקבלות גם תשובות שאומרות שההתפלגות בקירוב סימטרית, ולכן $E[Y] \approx 200$.

עבור $\text{Var}[Y]$ צריך להתאמץ קצת יותר, אך לא דרוש חישוב מדויק, ולא משנה איזה ערך מתוך

התא בחרתם עבור החישוב.

$$\text{Var}[Y] = E(Y^2) - E(Y)^2 \approx$$

$$\frac{24 \cdot 75^2 + 1353 \cdot 125^2 + 3699 \cdot 175^2 + 3601 \cdot 225^2 + 1248 \cdot 275^2 + 75 \cdot 325^2}{10,000} - 199.605^2$$

$$= 2073.844$$

הערה: כאשר מחשבים ביד, לפעמים נוח יותר לחסר את ה"ממוצע"

ולהניח סימטריה. אז:

$$\text{Var}[Y] \approx E((Y - 200)^2) \approx \frac{24 \cdot 125^2 + 1353 \cdot 75^2 + 3699 \cdot 25^2 + 3601 \cdot 25^2 + 1248 \cdot 75^2 + 75 \cdot 125^2}{10,000}$$

בפרט, התוצאה תהיה ממוצע משוקלל של מספרים בין 25^2 ל- 125^2

ג. **[14 נק']** הניחו שמספר הפרגמנטים מתפלגים פוואסון לא אחיד:

$$Y_k \sim \text{Poisson}(\lambda_k), \quad \lambda_k \sim F,$$

כאשר F התפלגות של התוחלת על פני התאים השונים.

אמדו בקירוב (1) את השונות שאיננה ניתנת להסברה ו(2) את שונות התוחלות $\text{Var}[E[Y]]$.

השתמשו באומדנים של התוחלת והשונות שחישבתם בסעיף ב.

נשתמש בנוסחא לפירוק השונות שנתנה בכיתה:

$$Var[Y] = Var_K[E_{Pois}[Y_k]] + E_k[Var_{Pois}[Y_k]].$$

נזכור מהם האיברים בנוסחא זו:

$E_k[Var_{Pois}[Y_k]] = \frac{1}{K} \sum Var_{Pois}[Y_k]$ זהו השונות שאיננה ניתנת להסברה, מכיוון שנובעת מהגרלות רנדומיות של פואסון. במקרה שלנו:

$$Var_{Pois}[Y_k] = \lambda_k, \quad E_k[Var_{Pois}[Y_k]] = \bar{\lambda}$$

ניתן לאמוד בקירוב טוב את $\bar{\lambda}$ בעזרת האומד לתוחלת של מכיוון ש $E_k[E_{Pois}[Y_k]] = E[Y]$

שונות התוחלות היא $Var_K[E_{Pois}[Y_k]] = \frac{1}{K} \sum (\lambda_k - \bar{\lambda})^2$ (לא חייבים לכתוב).

ניתן לאמוד מתוך הנוסחא למעלה:

$$Var_K[E_{Pois}[Y_k]] = Var[Y] - E_k[Var_{Pois}[Y_k]] = Var[Y] - \bar{\lambda}.$$

נציב את האומדים שלנו ל $\bar{\lambda}$, $Var[Y]$ ונקבל:

$$\widehat{Var}_K[E_{Pois}[Y_k]] = \widehat{Var}[Y] - \hat{E}[Y]$$

נציב את הערכים ונקבל שהשונות שאיננה ניתנת להסברה בקירוב 200 והשונות של התוחלות היא בקירוב 1870.

ד. **[11 נק']** דן אמד מודל המתאר את השפעת GC על מספר הפרגמנטים בתא.

כאשר בדק את ממוצע ריבועי השגיאה על נתוני ה train (נתוני האימון):

$$\frac{1}{K_{tr}} \sum_{k \in Train} (Y_k - \hat{f}(GC_k))^2$$

קיבל שגיאה נמוכה בהרבה מהשונות שאיננה ניתנת להסברה (ע"פ מודל פואסון לא אחיד). הסבירו בקצרה כיצד זה יתכן, ומה המשמעות של מצב כזה.

אין מניעה לקבל בנתוני ה train שגיאה שנמוכה מהשונות הבלתי ניתנת להסברה. אם היינו רואים מצב כזה בנתוני ה test, היינו צריכים להיות מודאגים שמא יש לנו "באג" או שעשינו טעות בחישוב.

עם זאת, זהו מצב של overfitting, כלומר הפונקציה $\hat{f}(GC_k)$ כנראה תפסה לא רק את הקשר בין פרגמנטים GC, אלא גם את הרעש בנתוני ה train. במקרים כאלו, כנראה שממוצע ריבועי השגיאה על נתוני ה test יהיו משמעותית יותר גבוהים מאלו ב train.

