

מעבדה בסטטיסטיקה 52568 התשע"ח
בוחן מסכם – דף הנחיות.

הנחיות: הבוחן כולל 2 שאלות המורכבות ממספר סעיפים. עליכם לענות בטופס הבחינה ובאופן עצמאי על כל השאלות. יש להסביר בקצרה כל תשובה במקום הנתון לה בלבד ובכתב ברור.

חומר עזר: מחשבון.


משך הבחינה: שעה

שאלה 1

עדי רוצה לאמוד קו רגרסיה המקשר בין מספר הפרגמנטים בתא וכמות הGC. היא החליטה לאמוד רגרסיה המורכבת ממקטעים ישרים, וכתבה את הנוסחה הבאה:

```
lm(formula = FRAG ~ I(1 * ( GC < 0.4 ) ) + I(GC * ( GC < 0.4 ) ) +  
  I(1 * ( GC >= 0.4 ) ) + I(GC * ( GC >= 0.4)), subset = train_samp)
```

הרגרסיה שאמדה מסומנת בקו מלא בגרף.



א. [15 נק']

נסמן בX את מטריצת המודל הליניארי (בX 4 עמודות וח שורות). כתבו את השורות של X המתאימות לנקודה עם GC=0.3 ולנקודה עם GC=0.5.

ב. [20 נק']

ראזי הציע לעשות רגרסיית מקלות שבורים במקום הרגרסיה של עדי. הרגרסיה מתוארת בקו מנוקד. סמנו את התשובה הנכונה והסבירו בקצרה.

ההטיה בריבוע הממוצעת של המודל החדש (ראזי):

1. גדולה משל המודל של עדי.

2. קטנה מהמודל של עדי.

3. לא ניתן לדעת.

ג. [10 נק']

הסבירו מדוע נקודת אי רציפות, כמו זו שיש במודל של עדי, היא תכונה לא רצויה עבור פונקציית GC. (רמז – מה יקרה כשנסה לאמוד עותקים?).

שאלה 2

דן רוצה לבדוק את התפלגות הפרגמנטים ב-10,000 תאים. הוא משתמש בפונקציית היסטוגרמה ומקבל את הגרף והפלט הבאים:

```
> h
$breaks
[1] 50 100 150 200 250 300 350

$counts
[1] 24 1353 3699 3601 1248 75


$density
[1] 0.000048 0.002706 0.007398 0.007202 0.002496 0.000150

$mids
[1] 75 125 175 225 275 325

$xname
[1] "dat"

$equidist
[1] TRUE

attr(,"class")
[1] "histogram"
```



א. **[15 נקודות]** הציעו שלושה שיפורים שיהפכו את הגרף ליותר אינפרמטיבי.

הצעה 1

הצעה 2

הצעה 3

ב. **[10 נק']** השתמשו בהסטוגרמה כדי לאמוד בקירוב את $E[Y]$ ואת $Var[Y]$.

$E[Y] \approx$ _____

$Var[Y] \approx$ _____

ג. [14 נק] הניחו שמספר הפרגמנטים מתפלגים פואסון לא אחיד:

$$Y_k \sim \text{Poisson}(\lambda_k), \quad \lambda_k \sim F,$$

כאשר F התפלגות של התוחלת על פני התאים השונים.

אמדו בקירוב (1) את השונות שאיננה ניתנת להסברה ו(2) את שונות התוחלות $\text{Var}[E[Y]]$.

השתמשו באומדנים של התוחלת והשונות שחישבתם בסעיף ב.

ד. [11 נק] דן אמד מודל המתאר את השפעת ה-GC על מספר הפרגמנטים בתא.

כאשר בדק את ממוצע ריבועי השגיאה על נתוני ה- train (נתוני האימון):

$$\frac{1}{K_{tr}} \sum_{k \in \text{Train}} \left(Y_k - \hat{f}(GC_k) \right)^2$$

קיבל שגיאה נמוכה בהרבה מהשונות שאיננה ניתנת להסברה (ע"פ מודל פואסון לא אחיד).

הסבירו בקצרה כיצד זה יתכן, ומה המשמעות של מצב כזה.
